

ESTUDO DE VEÍCULO AUTÔNOMO: SISTEMA DE NAVEGAÇÃO PARA VEÍCULOS AGRÍCOLAS

Ricardo Yuji Takano¹, Anderson Pires Rocha²

1. Acadêmico da UniMetrocamp – Wyden Brasil, Engenharia de Controle e Automação, ricardotakano7@gmail.com

2. Professor Orientador – UniMetrocamp – Wyden Brasil, anderson.rocha@unimetrocamp.edu.br

Resumo

Este trabalho apresenta um estudo de veículos autônomos, através do desenvolvimento de um sistema de navegação aplicado em um protótipo de veículo agrícola. A agricultura desempenha um importante papel à população por fornecer alimentos e insumos tanto para humanos como para animais. Essa importância, combinada com o aumento populacional tem alavancado cada vez mais as pesquisas e desenvolvimento de novas tecnologias no ambiente agrícola, buscando aumentar a eficiência e produtividade, o que motivou o desenvolvimento deste trabalho. Para isso o sistema de navegação desenvolvido utilizou uma câmera, dois módulos GPS e três sonares que, operando em conjunto, possibilitaram ao protótipo percorrer um trajeto em linha reta em um ambiente de simulação controlado de forma confiável.

Palavras-chave:

Veículo autônomo. Sistema de navegação. Sistema global de posicionamento. Agricultura de precisão. Trator agrícola.

1. Introdução

A temática de veículos autônomos vem ganhando destaque na indústria e no ambiente acadêmico, tendo em vista uma melhora na qualidade de vida das pessoas, maior praticidade no dia a dia, redução de stress e desgaste físico e, principalmente, redução no índice de acidentes de trânsito, conforme mostrado por LITMAN (2018). De acordo com o Observatório Nacional de Segurança Viária (ONSV, 2019, documento eletrônico), 90% dos acidentes de trânsito são causados por falhas humanas, que podem envolver desde a desatenção dos condutores até o desrespeito à legislação, tornando os veículos autônomos ainda mais atrativos.

Um veículo autônomo pode ser definido como qualquer veículo terrestre capaz de locomover sem a necessidade de um condutor humano (SAE J3016, 2014, apud LITMAN, 2018). O que torna isso possível é a utilização de diversos sensores, câmeras, GPS, radares e sonares que, juntamente com algum tipo de inteligência

artificial, consegue interpretar os dados obtidos e definir as melhores ações para mover o veículo na direção correta.

Tendo em vista esses ganhos com a evolução no desenvolvimento dos veículos autônomos, inúmeros projetos e protótipos já foram propostos e desenvolvidos a fim de alcançar o método mais eficaz e confiável para atingir tal objetivo, como por exemplo os carros autônomos da Google (WAYMO, 2009) e Tesla (TESLA, Inc. 2016) e tratores autônomos da CNH (CNH Industrial, 2017) e John Deere (ALLEN, 2019). Os maiores receios ao pensar em um veículo não controlado por seres humanos é em relação à segurança e à confiabilidade, por isso a grande maioria dos trabalhos dessa área propõe a utilização de mais de um meio de aquisição de dados do ambiente ao redor do veículo.

Para o trabalho proposto, o foco se deu no estudo e desenvolvimento de um protótipo para aplicação agrícola. Essa temática foi escolhida, primeiramente, pela maior acessibilidade nesse tipo de ambiente, uma vez que trata-se de um local a céu aberto, com menor concentração de pessoas e animais e ausência de tráfego de veículos e também pela importância da agricultura para a sociedade, sendo a responsável pelo cultivo de alimentos, combustíveis, medicamentos, matéria-prima para vestuário e outros itens indispensáveis ao ser humano.

Nesse sentido pode-se encontrar publicações com diferentes enfoques e estratégias como citados adiante. Alguns trabalhos utilizaram um GPS RTK, giroscópio e clinômetro para realizar um trajeto previamente planejado (OKSANEN, 2015), outros foram um pouco além, utilizando além do GPS RTK e do giroscópio, uma câmera para aquisição de imagem do ambiente, possibilitando que o trajeto seja definido através das imagens da câmera (NOGUCHI, et al., 2001; ZHANG; REID; NOGUCHI, 1999). Foram feitos trabalhos também utilizando sensores de feixes de laser, onde foram colocados pontos refletores em volta da área desejada e através da triangulação possibilitou definir a localização exata do veículo no local (AHAMED, et al., 2004; HOLMQVIST, 1993; TATSUNO, et al., 2005).

Baseado nos trabalhos já realizados, o presente trabalho propõe a utilização de 03 (três) formas diferentes para obtenção de dados do meio externo, 02 (dois) módulos GPS, 01 (uma) câmera e 03 (três) sonares. Através da utilização dessas 03 (três) formas de captação de dados pretende-se garantir que o veículo seja capaz de percorrer o trajeto de uma fileira de uma plantação em linha de forma precisa e confiável. Além disso, propõe-se a utilização de itens de baixo custo, um sistema de

filtro dos dados e inteligência que possibilitem a obtenção de um resultado similar aos obtidos com a utilização de sistemas com custos mais elevados.

2. Referencial teórico

De acordo com o artigo de LITMAN (2018), veículos autônomos podem proporcionar diversos benefícios à sociedade, podendo tornar os deslocamentos mais produtivos e menos estressantes, possibilitar que pessoas com deficiência ou até mesmo pessoas que ainda não podem ou não deveriam dirigir utilizem esse tipo de veículo sem problemas e de maneira segura, maior abertura para ser utilizado de forma compartilhada, minimizando danos às estradas e ao meio ambiente. No meio agrícola, muitas dessas vantagens descritas por Litman continuam válidas.

Já no trabalho de ZHANG, REID e NOGUCHI (1999) foi desenvolvido um sistema de navegação para um veículo agrícola utilizando sensores redundantes sendo eles uma câmera, um giroscópio e um GPS RTK. Para a câmera, foram utilizados um filtro infravermelho de proximidade para aumentar a discriminação entre as cores das plantas e do solo baseado no trabalho de REID (1986)(figura 1). Além disso foram utilizados dois métodos para detecção da linha da plantação, um método heurístico e outro utilizando a transformada de Hough.

O método heurístico utilizado para definição da direção se deu através da detecção dos segmentos na imagem. Através da classificação não supervisionada foi possível determinar pontos em diferentes classes de diretrizes. Cada uma dessas classes foi utilizada para determinar a trajetória da diretriz na imagem e então sim, era determinado o ponto de desaparecimento, ou seja, o ponto onde a reta desaparecia na imagem. Esse ponto definiu a direção que o veículo deveria seguir.

O método utilizando a transformada de Hough é semelhante, porém a transformada é capaz de definir as linhas presentes na imagem e a partir das linha identificadas o ponto de desaparecimento é definido e consequentemente a trajetória do veículo.

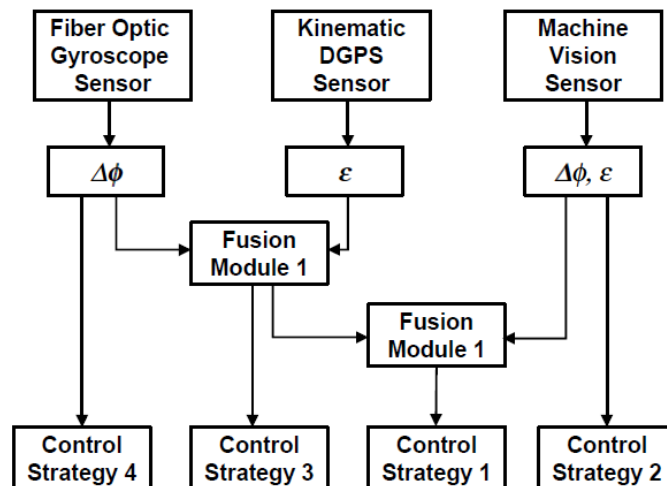
Figura 1 - Imagem das linhas de plantação



Fonte: REID, John F. (1986).

Por fim foi criado um módulo de fusão dos dados dos sensores para definir qual a melhor estratégia de controle a ser usada (figura 2).

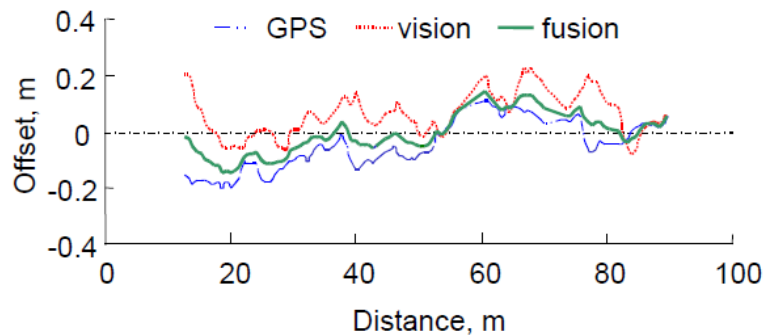
Figura 2 - Diagrama de blocos do sistema utilizando módulo de fusão dos sensores



Fonte: ZHANG, REID e NOGUCHI (1999).

Ao fim dos testes o modelo foi capaz de operar com desvio máximo de 0,15 metros utilizando o módulo de fusão dos sensores e os dados mostraram que ele conseguiu compensar erros grandes causados pelos sensores se usados de forma independente (figura 3).


Figura 3 - Comparativo da precisão entre o sistema de visão, o GPS e a fusão dos sensores.



Fonte: ZHANG, REID e NOGUCHI (1999).

Outro estudo realizado foi o de BLACKMORE, et al. (2004) sobre desenvolvimento de um trator autônomo determinístico. Nesse trabalho um trajeto pré-determinado era enviado para o trator que o percorria utilizando um GPS RTK somente. Para obter melhor precisão foi utilizado um controlador PID e um filtro Kalman. Após os testes percebeu-se que o sistema foi capaz de realizar o percurso de maneira satisfatória, com erro de no máximo 10cm, porém além de necessitar a calibração do filtro Kalman antes de iniciar o processo, houve um desvio de aproximadamente 1 (um) metro na primeira corrida devido à perda de sinal em certo ponto do trajeto (figura 4).

Figura 4 - Pontos mostrando o trajeto planejado versus o trajeto realizado.



Fonte: BLACKMORE, et al. (2004).

Baseado nos trabalhos analisados, pode-se perceber que a utilização de somente um sistema de aquisição de dados não é confiável, sendo suscetível à falhas.

e perda de sinal. No entanto, a utilização de um PID e do filtro Kalman tornaram o modelo em geral funcional e com desempenho razoável. Já com a utilização de mais sistemas de aquisição, unidos a um modelo de fusão desses dados, foi possível atingir um modelo mais preciso e robusto. No trabalho realizado foi escolhido seguir a linha do trabalho de ZHANG, REID e NOGUCHI (1999), porém com a utilização de sistemas diferentes de aquisição de dados, a fim de fornecerem robustez e confiabilidade.

3. Metodologia

Durante o curso de graduação em engenharia de controle e automação os alunos são apresentados a diversas disciplinas, em geral de exatas, para que sejam capazes de, ao final do curso, entender e projetar sistemas de automação aplicando os conhecimentos adquiridos. Conforme mostrado por CUNHA, LEÃO e LIMA (2000), matérias de laboratório com aulas práticas, separadas de aulas teóricas, torna o aprendizado mais amplo, mais interativo e muito mais próximo à realidade vivenciada por um profissional de engenharia.


Em uma dessas disciplinas responsáveis por testar os conhecimentos de forma prática, os alunos devem estudar e projetar um *ROVER* (veículo utilizado em explorações espaciais podendo ou não ser completamente autônomo) que consiga se movimentar de forma autônoma utilizando sensores fotoelétricos, sonares e uma câmera.

Baseado nesse projeto, o presente estudo implementou melhorias de baixo custo no sistema de navegação do *ROVER* através da utilização de um sistema de navegação mais elaborado e inteligente, além da inclusão do GPS como um quarto dispositivo guia, para ser utilizado em um ambiente agrícola.

3.1. Estrutura Mecânica

O chassi do *ROVER* foi desenvolvido por alunos de semestres anteriores, utilizando treliças de alumínio em sua estrutura e seguindo as seguintes medidas (figura 5).

Figura 5 - Estrutura mecânica do protótipo.



Fonte: Disciplina de Integração e Avaliação de Sistemas (Unimetrocamp Wyden).

Figura 6 - Protótipo ROVER completo.



Fonte: Protótipo adaptado pelo autor (2019).

Para mover o *ROVER* foram utilizados dois motores DC, um em cada roda traseira, modelo MOTRON MR 910-115 12V/24V, com caixa de redução para 20W/94kgf/cm. Através da diferença na velocidade de acionamento dos motores é possível fazer com que o veículo realize a mudança na direção de sua trajetória, não sendo necessário um motor para controle da roda dianteira.

3.2. Hardware Eletrônico

Para a parte eletrônica do protótipo foi utilizado um microcontrolador Arduino Mega 2560 devido à sua vasta gama de aplicação, grande quantidade de portas e

desempenho condizente com o projeto proposto. Além disso trata-se de um dispositivo de baixo custo, fácil de programar e, por ser um hardware livre, possui uma quantidade muito grande de material disponível para aplicação em projetos.

Além disso, para controle dos motores DC pela placa Arduino, foi utilizada uma ponte H modelo Shield Super Motor Driver VNH5019, que possibilita o controle tanto da velocidade de giro, como do sentido de giro dos motores, possibilitando controlar melhor a velocidade de giro do *ROVER*.

3.3. Dispositivos de aquisição de dados

Para a parte dos sensores, foram utilizados 03 (três) sonares modelos HC-SR04, capaz de medir distâncias de até 4 metros num ângulo de aproximadamente 30 graus.

Para a aquisição das imagens foi utilizado uma câmera modelo Logitech V-UAR38 de 1.3 Megapixels.

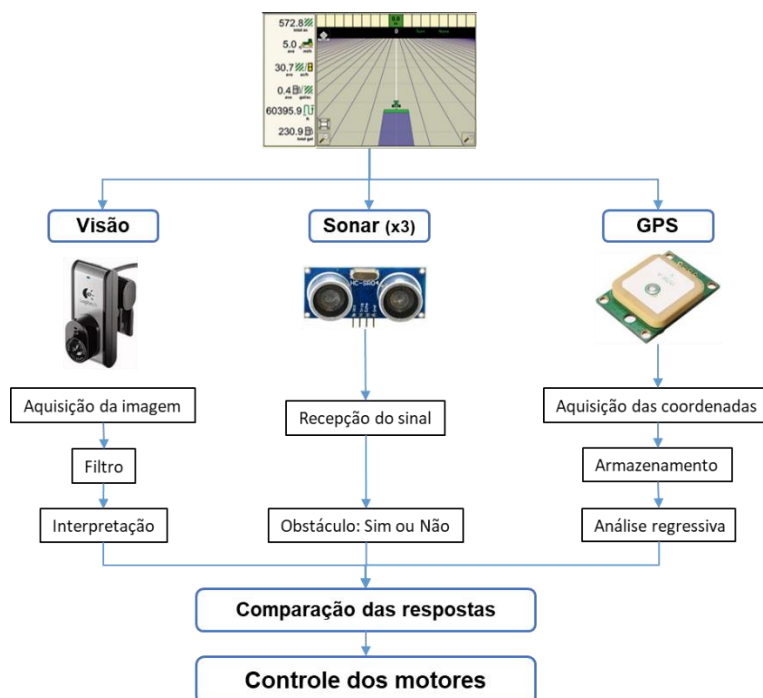
Por fim, para captação do posicionamento via satélite foram utilizados 02 (dois) módulos GPS modelo GY-NEO6MV2.

Todos os itens foram escolhidos por possuírem baixo custo e precisão adequada ao trabalho em questão. Outro fator importante para a escolha dos componentes foi a sua facilidade de aplicação, compatibilidade entre os dispositivos e quantidade de material de referência disponível para consulta.

3.4. Sistema de navegação

Visando obter um protótipo com alta precisão, confiabilidade e robustez, foram utilizados 3 tipos de dispositivos para obtenção de dados. A utilização de dispositivos redundantes, conforme mostrado nos trabalhos de ZHANG, REID e NOGUCHI (1999), através da fusão dos dados é possível atingir um nível de precisão mais alto, onde os pontos negativos de um sensor são corrigidos pelos outros dispositivos. A estratégia utilizada para a integração é mostrada abaixo (figura 7).

Figura 7 - Fluxograma do sistema de navegação



Fonte: Elaborada pelo autor (2019).

3.4.1. Sistema de visão

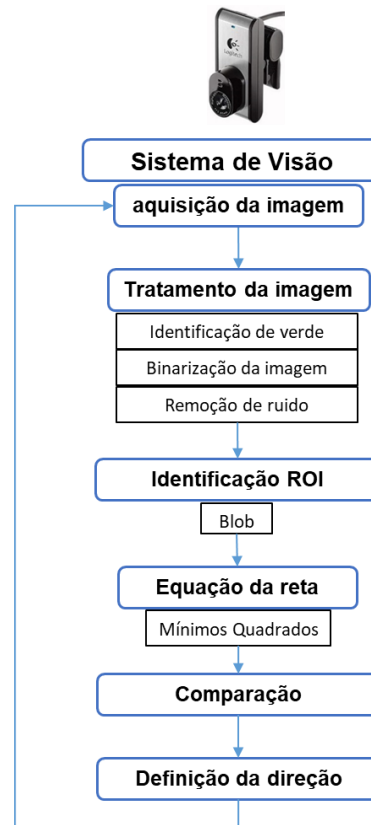
Na literatura, diversas técnicas já foram testadas e utilizadas para se chegar a um sistema confiável, com a utilização da visão de máquina, visando supervisionar e até por vezes controlar o veículo, tentando sempre mantê-lo na faixa correta. Além dos trabalhos de ZHANG, REID e NOGUCHI (1999) e PILARSKI, et al. (1998), pode-se citar o trabalho de GONZALEZ-DE-SANTOS, et al. (2017) e GARCÍA-SANTILLÁN, et al. (2018) como algumas dessas técnicas testadas.

Diversos desses sistemas estão relacionados à condução em perímetro urbano e, mais especificamente, para sistemas de utilização em rodovias, pela maior facilidade na aplicação por se tratar de uma movimentação mais uniforme na maior parte do tempo. Trabalhos como o de KIPPENBROCK (2017) e SHAH (2018) apresentam diferentes estratégias para atingir tal objetivo.

Alguns trabalhos também podem ser encontrados com foco em veículos autônomos para aplicações agrícolas, porém grande parte destes utilizam o sistema GPS ao invés da câmera, principalmente pelo fato de muitas vezes o trator a ser utilizado já possuir esse dispositivo. Pode-se citar os trabalhos realizados por OKSANEN (2015), KISE, et al. (2001) e O'CONNOR, et al. (1996).

Utilizando os trabalhos citados como base, a estratégia adotada para o sistema de visão se divide em algumas etapas sendo elas: tratamento da imagem, identificação da região de interesse (ROI), equação da reta, definição do trajeto e por fim análise do posicionamento do veículo para direcionamento, conforme ilustra o diagrama.

Figura 8 - Fluxograma do sistema de visão



Fonte: Elaborada pelo autor (2019).

Para a realização do sistema de visão do veículo, é utilizado o software Visual Studio 2017 com a linguagem C# e as bibliotecas Aforge.CV e easywebcam. O sistema para desenvolvimento é um Windows 2010 Home 64 bits em um processador intel i7 2.30GHz e as imagens captadas pela câmera possuíam resolução de 320 por 240 pixels no sistema de cores RGB.

Na primeira etapa do tratamento da imagem adquirida pela câmera (figura 1), é utilizado um filtro para diferenciação da cor verde para as demais. Para isso, foram utilizados como base os trabalhos de YANG, et al. (2015), GUIJARRO, et al. (2010) e também o de MEYER e CAMARGO NETO (2008). Em todos esses trabalhos foram analisados e comparados filtros para identificação de plantas. Após analisar os resultados, foi escolhido o filtro “Excess Green”.

Figura 9 - Imagem original a ser tratada




Fonte: USDA NRCS South Dakota (2014).

Seguindo a linha desses autores, primeiramente foi realizada a normalização dos valores RGB da imagem (figura 10) através da equação 1, onde r , g e b são os valores normalizados. No Visual Studio, os valores de R , G e B de cada pixel da imagem foram extraídos e, conforme mostrado na equação cada valor foi dividido pela soma de todos (R , G e B), gerando um valor menor ou igual a um. Para recolocar o pixel normalizado, o valor resultante da operação anterior foi multiplicado por 255 (valor máximo para cada variável RGB).

Após esse processo foi aplicado o filtro escolhido. Para realizar essa aplicação foi necessário realizar uma operação matricial, de forma a se obter os valores especificados pela equação 2. Para tal, foi criada uma matriz 5×5 (conforme equação 3), que representam os valores do filtro “*Excess Green*”. Para cada pixel, o vetor com os valores R , G , B , α e β (onde α representa o nível de transparência da cor e β representa um fator fictício, usado apenas para operações de translação da imagem) foi extraído e multiplicado pela matriz, conforme apresentado na equação 3.

Figura 10 - Normalização dos valores RGB da imagem



Fonte: Modificado pelo autor (2019).

$$r = \frac{R}{R + G + B}, g = \frac{G}{R + G + B}, b = \frac{B}{R + G + B} \quad (1)$$


$$ExG = 2g - r - b \quad (2)$$

$$\begin{matrix} [0.2 & 0.7 & 0.4 & 1.0 & 1.0] * \\ \text{R} & \text{G} & \text{B} & \alpha & w \end{matrix} \begin{bmatrix} 0 & -1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} = [0 \ 0.8 \ 0 \ 1 \ 1] \quad (3)$$

ExG

O “Excess Green” foi escolhido por possuir resultados extremamente satisfatórios para a proposta do trabalho e também por ser relativamente mais simples de se aplicar que os demais, necessitando apenas de uma transformação na matriz de cores da imagem (figura 11).

Figura 11 - Aplicação do filtro "Excess Green"



Fonte: Modificado pelo autor (2019).

Por fim, é realizada a binarização da imagem através do método de Otsu (1979), capaz de selecionar automaticamente o valor de *threshold* (limiar) da imagem através de um processo de critério discriminante (figura 12). O método trata-se de uma melhoria da equação 4, onde “ σ ” é a variância intraclasse, “ W ” é o peso dado para cada classe e “ b ” e “ f ” correspondem a fundo (*background*) e frente (*foreground*) respectivamente.

$$\sigma_W^2 = W_b \sigma_b^2 + W_f \sigma_f^2 \quad (4)$$

Conforme explicado por TOROK (2016) em seu artigo, Otsu provou ser possível substituir a equação anterior por outra (equações 5 e 6) com menor custo computacional. Sua ideia foi de, ao invés de encontrar o valor que minimize a variância


intraclasse, buscar o valor que maximize a variância interclasse, visto que ambos resultam no mesmo valor conforme demonstrado por Otsu.

$$\sigma_B^2 = \sigma^2 - \sigma_W^2 = W_b(\mu_b - \mu)^2 + W_f(\mu_f - \mu)^2 \quad (5)$$

$$\mu = W_b\mu_b + W_f\mu_f = W_bW_f(\mu_b - \mu_f)^2 \quad (6)$$

No código desenvolvido, o método de Otsu foi aplicado utilizando-se funções retiradas do site “Programming Algorithms” (2015). As funções extraem o histograma da imagem, percorrem todo o histograma analisando todos os valores de *threshold* (limiar) possíveis, armazena os valores das variâncias interclasse em um vetor e por fim retorna o maior valor armazenado no vetor, ou seja, o valor que maximiza a variância conforme as equações de Otsu.


Figura 12 - Aplicação da binarização pelo método de Otsu



Fonte: Modificado pelo autor (2019).

Para finalizar essa etapa, é utilizada a função “blob” que identifica os corpos presentes na imagem. Após identificados eles são classificados em ordem decrescente e os dois maiores serão as regiões de interesse (ROI), ou seja, as regiões referente às duas linhas de plantação por onde o veículo deverá trafegar (figura 13).

Figura 13 - Imagem final. ROI extraídas, bordas linearizadas e direção definida



Fonte: Modificado pelo autor (2019).

Após encontrar as linhas de plantação, foi calculado a melhor linha que se ajuste aos pontos das bordas do nosso ROI (figura 13 – linhas azuis). Para tal, foi escolhido o método dos mínimos quadrados (BAGLIVO, 2005), por se tratar do método mais simples e mais comumente utilizado como forma de regressão linear, além de fornecer uma solução bastante razoável para se encontrar a melhor reta dados um conjunto de ponto, conforme WEISSTEIN (2002).

O método irá, basicamente, buscar o melhor ajuste para um conjunto de dados, tentando minimizar o somatório dos quadrados dos erros de cada ponto. Isso é feito através das equações 7, 8 e 9. Elas foram aplicadas ao sistema percorrendo cada ponto das bordas desejadas das regiões de interesse.


$$Y = aX - b \quad (7)$$

$$a = \frac{\left(\frac{\sum_{i=0}^N X * Y}{N} - \bar{X} * \bar{Y} \right)}{\left(\frac{\sum_{i=0}^N X * X}{N} - \bar{X} * \bar{X} \right)} \quad (8)$$

$$b = a * \bar{X} - \bar{Y} \quad (9)$$

Na figura 14 é ilustrado o método aplicado a um conjunto de dados desordenados. Pode-se ver que a aproximação da reta utilizando o método é capaz de fornecer uma resposta adequada ao que se deseja.

Figura 14 - Exemplo de aplicação do método mínimos quadrados



Fonte: BAGLIVO, Jenny A. (2005).

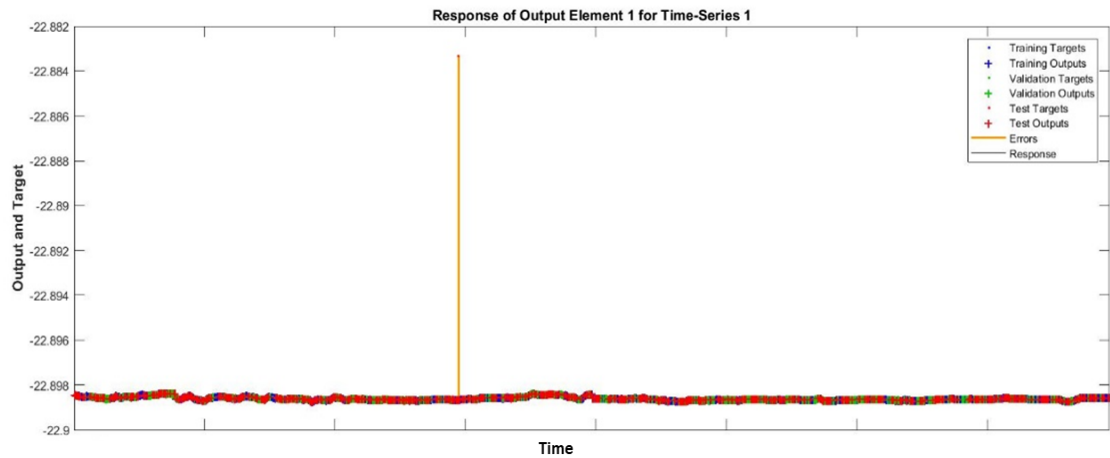
Utilizando essas linhas que delimitam a rota do veículo (figura 13 – linhas azuis), foi definido o meio no eixo x (largura), entre os pontos dessas duas linhas, para os pontos a um quarto da imagem (referente a altura da imagem, de baixo para cima) e para um oitavo da altura da imagem (figura 13 – linha bordô). Comparando com os outros dois pontos da linha referente à direção atual do ROVER (figura 13 – linha laranja), podemos prever se existe uma alteração de direção pelos pontos a um quarto da altura da imagem e pelos pontos a um oitavo da altura da imagem fazemos a comparação para definir a direção que o *ROVER* deve virar de acordo com o ângulo calculado, conforme mostrado na figura 13.

3.4.2. Sistema GPS

Os dados dos GPS serão captados e armazenados na memória. Utilizando os dados obtidos o sistema calcula a diferença para os dados anteriores de latitude e longitude e assim consegue prever qual serão os próximos pontos caso haja perda de sinal do GPS. Além disso, foi decidido utilizar dois módulos GPS para que haja sempre um backup caso um deles falhe ou perca sinal. Esses cálculos serão utilizados somente no caso dos outros dispositivos de aquisição de dados pararem de funcionar e o veículo depender exclusivamente dos GPS, uma vez que, devido à imprecisão do GPS utilizado (aproximadamente 7 metros), esse tipo de sistema não é suficientemente confiável para uma plantação.

Foram realizados testes de validação dos dados dos módulos GPS para verificar sua precisão e assertividade. Após serem armazenados em arquivo de texto, esses dados foram tratados e salvos em um arquivo Excel. Utilizando o software Matlab, os dados foram inseridos em uma rede neural no modo Dynamic Time Series. A rede gerou a saída mostrada abaixo (figura 11), onde é possível ver que ela foi capaz de aprender e gerar uma linha de tendência praticamente reta, pelo fato dos dados terem sido de uma posição fixa.

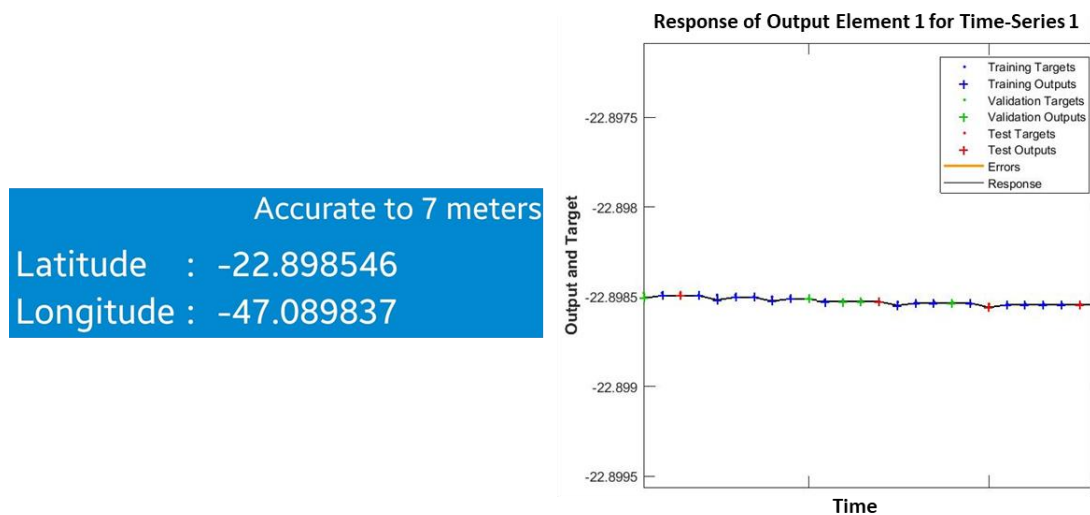
Figura 15 - Gráfico da saída após análise da rede neural



Fonte: Elaborada pelo autor (2019).

Aproximando mais o gráfico e comparando com dados de GPS de um dispositivo móvel (figura 16) com precisão de 07 (sete) metros, pode-se perceber que os dados estão coerentes e conversam entre si, permitindo validar os dados obtidos pelos dois módulos GPS e comparar sua precisão com as de um GPS de dispositivo móvel.

Figura 16 - Comparativo entre os dados dos GPS e de um dispositivo móvel



Fonte: Elaborada pelo autor (2019).

3.4.3. Sistemas auxiliares

Os sonares foram utilizados para casos em que um obstáculo não for desviado ou então o veículo errar seu trajeto e invadir a linha de plantação, fornecendo um sistema de segurança ao *ROVER*. Os sonares também podem e devem ser ajustados

conforme a altura da plantação para que forneça uma precisão mais adequada ao ambiente.

3.5. Fusão dos sensores

Para a utilização dos sistemas de forma conjunta, foi primeiramente priorizado os valores dos sonares, em seguida os dados da câmera e por fim os dados do GPS como backup. Assim tem-se dados redundantes que possibilitam ao veículo continuar operando mesmo que algum dos sensores falhe.

Após coletar os dados é tomada a decisão, sempre priorizando os dados dos sonares, pois estes se tratam de sensores que irão identificar possíveis obstáculos no caminho do veículo e garantem que não haverá colisão durante o trajeto.

4. Resultados e discussão

Para este trabalho, o sistema foi testado em um dia de sol, em horário com alta luminosidade (entre 12 e 15 horas) e em ambiente parcialmente controlado. O trajeto foi simulado utilizando papéis e tecidos para recriar o ambiente agrícola, tendo as cores marrom e verde em diferentes tonalidades. Além disso o sistema foi testado em um trajeto em linha reta, com trecho de aproximadamente 3 metros.

Com os testes realizados, foi possível obter dados do GPS coerentes e com precisão aceitável, no entanto o sistema não foi capaz de se locomover utilizando esses dados. Já o sistema de visão foi capaz de realizar parcialmente a tarefa de andar por uma linha de plantação reta sem danificar nenhuma planta, nesse ponto o sistema dos sonares foi capaz de evitar colisão e invasão na linha de plantação quando os outros sistemas não estavam operando corretamente.

O sistema, apesar de fornecer dados corretos em situações controladas, utilizando imagens paradas e dados do GPS sem haver movimento, foi capaz de desempenhar seu papel de forma correta em apenas 80% dos testes realizados, sendo estes com os sonares devidamente posicionados de acordo com a altura da plantação, a câmera previamente posicionada de acordo com o trajeto e o posicionamento do veículo, o veículo posicionado exatamente no centro da plantação, com alta iluminação e em um trajeto plano e reto.

5. Conclusão

Pode-se concluir que o sistema desenvolvido foi capaz de validar trabalhos já apresentados, além de descobrir melhorias para os sistemas de navegação autônoma. Através deste sistema foi possível entender e demonstrar como utilizar ferramentas de tratamento de imagem, aquisição de dados e gerenciamento de dados de diferentes sensores.

Foi possível desenvolver um sistema de navegação para um protótipo agrícola que consegue se locomover de forma autônoma, porém com baixa precisão e velocidade, devido a algumas falhas presentes no software, mas também pelo fato de se tratar de um sistema de baixo custo quando comparado a outros sistemas já desenvolvidos.

6. Trabalhos futuros

- Utilização de inteligência artificial na fusão e definição do dispositivo mais exato e mais eficiente para definir a direção.
- Inserção de filtros e controladores (PID) para melhora na navegação e utilização dos dados em tempo real.
- Utilização de sistema LIDAR (Light Detection and Ranging), capaz de mapear o ambiente ao redor através de um sistema a laser com varredura de 360°.
- Utilização de rede neural para trabalhar com os datalogs gerados pelos módulos GPS.
- Inclusão de sistemas de aquisição de dados, como acelerômetros, bússola e giroscópios.

Agradecimentos

Agradeço primeiramente ao meu orientador Anderson Pires Rocha pelo apoio e preocupação no desenvolvimento do presente trabalho. Também agradeço à minha família por todo suporte durante os anos de faculdade e à minha namorada pela ajuda, apoio, compreensão e por estar sempre ao meu lado nos momentos mais difíceis. Por fim agradeço à todos os docentes que tive durante minha graduação pelos ensinamentos e à faculdade Unimetrocamp e seus colaboradores por proporcionar essa instituição de ensino a nós alunos.

Referências

- AHAMED, T., et al. **Characterization of laser range finder for in-field navigation of autonomous tractor**. In: Proceedings of Conference on Automation Technology for Off-Road Equipment, Kyoto, Japan. 2004.
- ALLEN, James. **John Deere develops fully electric, autonomous tractor**. 2019. Disponível em: <https://bit.ly/2wNRvyY>. Acesso em: junho de 2019.
- BAGLIVO, Jenny A. **Mathematica Laboratories for Mathematical Statistics, Emphasizing Simulation and Computer Intensive Methods**. Vol. 14. 2005.
- BLACKMORE, B. S. et al. **Development of a deterministic autonomous tractor**. In: Proceedings CIGR. 2004.
- CNH Industrial. **Autonomous tractor technology shows way forward for farming: enhancing efficiency and working conditions in agriculture**. 2017. Disponível em: <https://bit.ly/2WutA1O>. Acesso em: junho de 2019.
- CUNHA, Flávio M.; LEÃO, José A.; LIMA, Euler N. C. **Metodologia para aulas de laboratório de circuitos elétricos: Relato de experiência**. Conferência Internacional de Ensino de Engenharia e Computação, São Paulo. 2000.
- GARCÍA-SANTILLÁN, Iván, et al. **Computer Vision-Based Method for Automatic Detection of Crop Rows in Potato Fields**. In: International Conference on Information Theoretic Security. Springer, Cham. 2018.
- GONZALEZ-DE-SANTOS, Pablo, et al. **Fleets of robots for environmentally-safe pest control in agriculture**. Precision Agriculture, v. 18, n. 4, p. 574-614. 2017.
- GUIJARRO, Maria, et al. **Automatic segmentation of relevant textures in agricultural images**. Computers and Electronics in Agriculture, v. 75, n. 1, p. 75-83. 2011.
- HOLMQVIST, R. **A laser optic navigation system for driverless vehicle**. Arnex Navigation AB, ARNBL, v. 344, p. 15. 1993.
- KIPPENBROCK, Ross. **Finding lane lines for self driving cars**. 2017. Disponível em: <https://github.com/rkipp1210/pydata-berlin-2017>. Acesso em: maio de 2019.

LITMAN, Todd. **Autonomous vehicle implementation predictions - Implications for transport planning**. Victoria Transport Policy Institute. 2018.

MEYER, George E.; CAMARGO NETO, João. **Verification of color vegetation indices for automated crop imaging applications**. Computers and electronics in agriculture, v. 63, n. 2, p. 282-293. 2008.

MOORTHY, S.; BOIGELOT, B.; MERCATORIS, B. C. N. **Effective segmentation of green vegetation for resource-constrained real-time applications**. In: Precision agriculture'15. Wageningen Academic Publishers. 2015.

NOGUCHI, Noboru et al. **Autonomous Agricultural Tractor with an Intelligent Navigation System**. IFAC Proceedings Volumes, v. 34, n. 19, p. 197-202. 2001.

OKSANEN, Timo. **Accuracy and performance experiences of four wheel steered autonomous agricultural tractor in sowing operation**. In: Field and service robotics. Springer, Cham. 2015.

ONSV. **Notícias**. 2019. Disponível em: <https://bit.ly/31HkhiR>. Acesso em: Maio de 2019.

OTSU, Nobuyuki. **A threshold selection method from gray-level histograms**. IEEE transactions on systems, man, and cybernetics, v. 9, n. 1, p. 62-66. 1979.

PILARSKI, Thomas, et al. **The demeter system for automated harvesting**. Autonomous Robots, v. 13, n. 1, p. 9-20. 2002.

PROGRAMMING ALGORITHMS. 2015. Disponível em: <https://bit.ly/2x6COHc>. Acesso em: junho de 2019.

REID, John F. **Automatic guidance of an agricultural tractor using computer vision**. Unpublished doctoral dissertation, Texas A&M University, College Station, TX. 1986.

SHAH, Y. **Lane detection using Matlab**. 2018. Disponível em: <https://github.com/ysshah95/Lane-Detection-using-MATLAB>. Acesso em: maio de 2019.

TATSUNO, Junya, et al. **2-D localization of autonomous farm vehicle using laser distance sensor**. Journal of the Japanese Society of Agricultural Machinery, v. 67, n. 5, p. 45-53. 2005.

TESLA, Inc. 2016. Disponível em: <https://bit.ly/2e7QRnA>. Acesso em: junho de 2019.

TOROK, Leonardo. **Método de Otsu**. Instituto de Computação, Universidade Federal Fluminense, Niterói. 2016.

USDA NRCS South Dakota. **Crop residue helps, but there's more to it for controlling soil erosion**. 2014. Disponível em: <https://bit.ly/2Y0Y6SF>. Acesso em: Maio de 2019.

WAYMO. 2009. Disponível em: <https://bit.ly/2iCZIBo>. Acesso em: junho de 2019.

WEISSTEIN, Eric W. **Least squares fitting**. From MathWorld--A Wolfram Web Resource. 2002. Disponível em: <https://bit.ly/2obybYy>. Acesso em: Junho de 2019.

WOEBBECKE, David M., et al. **Color indices for weed identification under various soil, residue, and lighting conditions**. Transactions of the ASAE, v. 38, n. 1, p. 259-269. 1995.

YANG, Wenzhu, et al. **A new approach for greenness identification from maize images**. In: International Conference on Intelligent Computing. Springer, Cham. 2015.

ZHANG, Qin; REID, John F.; NOGUCHI, Noboru. **Agricultural vehicle navigation using multiple guidance sensors**. In: Proceedings of the International Conference on Field and Service Robotics. 1999.